


dhiatoukebri@gmail.com

+216 56 810 124

dhia-elhak-toukebri

https://github.com/Dhia-69


# Dhia Elhak Toukebri

Data Engineer

## Profile

Étudiant en Data Engineering, passionné par la Data Science et l'Intelligence Artificielle, avec une expérience en programmation et en analyse de données.

## Langues

**Anglais** (B2)
**Français** (TCF-B2)
**Arabe** (Natif)
**Allemand** (A2)

## Compétences

- Code : **Python**, **Java**, **C**, **C++**, **C#**, **JavaScript**
- Bases de données : **SQL**, **MongoDB, MariaDB**
- AI : **Scikit-learn**, **TensorFlow**, **Keras**, **PyTorch, Transformers, LLMs**
- Data Viz : **Matplotlib**, **Seaborn**
- Data Manipulation : **Pandas**, **NumPy**
- Web : **Angular**, **.NET**, **Spring Boot**, **Flask**
- Mathématiques : **Algèbre, Probabilités, Stochastique, Statistiques avancées**
- Big Data : **Apache Hadoop, Hive, SuperSet, Zookeper, Kafka, AirFlow**
- Autres : **Docker**, **GitHub**, **GitLab**, **Postman**, **Swagger, BeautifulSoup, PowerBI**
- Soft Skills : **Discipline, Esprit d'équipe, Esprit Sportif, Communication, Leadership, Organisation, Créativité**

## Cértifications

**ETL and Data Pipelines with Shell, Airflow, and Kafka** (IBM)
**Data Scientist Associate** (DataCamp)
**Data Engineer Associate** (DataCamp)

## Centres d'intérêt

**Chef en Scouts** (2014 – 2024)
**Membre d'IEEE** (2020 – 2023)
**Sports** : Musculation, Natation, Football, Padel, Basket, Ping-pong

## Education

**Faculté des Sciences de Sfax, Tunisie** 2022 - 2025
3e année Cycle d'Ingénieur en Data Engineering

**Faculté des Sciences de Sfax, Tunisie** 2020 - 2022
Cycle Préparatoire Intégrée en Computer Science

**Lycée Habib Thameur de Sfax, Tunisie** 2016 - 2020
Baccalauréat Mathématique, Mention Assez Bien

## Expériences professionnelles

### AI Engineer
02/2025- présent

**Sofrecom** | Sfax, Tunisie

- Conception et déploiement d'un **Chatbot intelligent** pour la génération de requêtes SQL basé sur du **Prompt Engineering**, dans un environnement conteneurisé.
- Évaluation et optimisation de modèles **LLMs** pour améliorer la précision des requêtes générées.
- Développement d'une **interface interactive** permettant d'interagir avec le chatbot.
- **Python, Ollama, Transformers, NLP, LangChain, Streamlit, Docker, MariaDB.**

### Data Scientist
07/2024 - 09/2024

**Sofrecom** | Tunis, Tunisie

- Développement d'une application web innovante de contrôle parental intégrant l'**IA** pour la classification de contenu Adulte, avec **module d'authentification**.
- Pilotage du **cycle de vie des données** pour trois types de contenu (Collecte, Prétraitement, Augmentation).
- Développement et optimisation de modèles **ML/DL** atteignant des précisions de **92%** pour les textes, **97%** pour les images, **94,5%** pour les audios.
- **Python, TensorFlow, Keras, Flask, MongoDB, Hugging Face, Scikit-learn, Librosa, spaCy, Pydub, Git.**

### Développeur Full-stack
06/2023 - 08/2023

**AheadIT** | Tunis, Tunisie

- Développement de deux applications web en **architecture 3-tiers MVC** avec interfaces : gestion des matériels et gestion des collaborateurs/projets.
- Conception des bases de données, et développement et test d'**APIs REST**.
- **SQL Server, C#, TypeScript, Angular, ASP.NET, Postman, Swagger.**

## Projets académiques

### Analyse de fraude dans les transactions - Big Data
10/2024 - 01/2025

- **Surveillance et détection** de transactions frauduleuses en temps réel sur un dataset volumineux.
- **Configuration** de l'environnement **Big Data**, **stockage distribué** et **gestion des données sur un cluster optimisé** pour la scalabilité et la haute disponibilité.
- Visualisation et interprétation des résultats via des graphes.
- **Orchestration et automatisation** du système de bout en bout.
- **Python, VirtualBox, Kafka, Hadoop, YARN, Hive, Airflow, Hue, Superset, ZooKeeper.**

### Recyclage d'objets - Computer Vision
11/2024 - 01/2025

- Développement d'un **système intelligent** pour la **classification et le recyclage** des déchets
- Utilisation de **techniques de vision par ordinateur** pour l'identification automatique des matériaux recyclables (comparaison entre **hand-crafted, deep learning et Transformers**).
- **Optimisation et entraînement** du modèle avec des algorithmes de machine learning.
- **Python, HOG, LVP, Transformers, TensorFlow/PyTorch, OpenCV, Pickle.**

### Classification de vocabulaire de santé - NLP
03/2024 - 04/2024

- **Web Scraping** : Collecte à grande échelle d'articles de santé provenant de dizaines de e-sources.
- **NLP et ML** : Prétraitement de milliers de mots et développement d'un modèle de classification santé/non-santé atteignant une précision de **93%**.
- Implémentation d'un **système d'inférence temps-réel** traitant des milliers de documents quotidiennement.
- **Python, TF-IDF, Word2Vec, Regex, Streamlit, scikit-learn.**

### Churn Client-Enterprise - Data Science
02/2024 - 04/2024

- Gestion de **bout en bout**, incluant la **sélection, l'analyse, et la visualisation des données.**
- Pré-traitement, gestion des valeurs aberrantes, et extraction des caractéristiques pertinentes.
- Développement de modèles de prédiction du **Churn** Client avec des résultats optimisés : SVM (**78%**), KNN (**81%**), Gradient Boosting (**80%**), TabNet Classifier (**79%**).
- **Python, Scikit-learn, TensorFlow, PyTorch, Pandas.**